三、研究計畫內容（以中文或英文撰寫）：

（一）研究計畫之背景

無人機已廣泛應用於搜救、基礎設施巡檢與物流等任務。在 GPS 訊號不穩定或目標座標未知的情境下，無人機需依據自然語言描述，自主判讀畫面並飛抵目標，此即無人機視覺語言導航（Unmanned Aerial Vehicles Vision-Language Navigation, UAV-VLN）[2,6]。相較於在平面上移動的地面機器人 [1]，無人機須在三維空間中同時控制位置與姿態，承受重力與慣性約束，且其第一人稱視角隨飛行持續改變，使感知與控制的難度大幅提高 [6]。

視覺語言導航最早由 Anderson 等人 [1] 於室內地面場景提出，並以路徑長度加權成功率（Success weighted by Path Length, SPL）[11] 同時衡量成功與路徑效率。延伸至無人機後，TravelUAV [3] 以 AirSim [4] 建構連續三維飛行的導航平台，其 UAV-Need-Help 任務包含約 1.2 萬條人類操控軌跡，訓練集 7,922 條，測試集分為已見環境 1,418 條、未見物體 629 條與未見地圖 958 條，並以導航誤差（Navigation Error, NE）、成功率（Success Rate, SR）、Oracle 成功率（Oracle Success Rate, OSR，飛行軌跡中任一時刻曾進入成功範圍即視為成功 [1]）與 SPL 評估，成功定義為停止於目標 20 公尺以內 [6]。

現有 UAV-VLN 方法可依控制粒度分為兩類 [6]。第一類以高階規劃或航點預測為主，例如 TravelUAV [3]、NavFoM [18] 與 LongFly [17]，由模型預測航點後交由低階控制器執行。此類方法將感知與控制解耦，容易遺失細緻的視覺線索，並增加系統延遲。第二類為端對端連續控制，在機器人操作領域，RT-2 [20] 與 OpenVLA [5] 已證明將動作視為語言 token 的端對端視覺語言動作（Vision-Language-Action, VLA）具備良好的泛化能力。在無人機應用上，RaceVLA [19] 將 OpenVLA 微調用於競速無人機，但多侷限於賽道等結構化環境 [6]。

此外，第一類方法多仰賴兩項外部輔助：其一是由預錄最佳軌跡推導、逐步注入提示詞的方向指引（oracle guidance），其二是用以判斷降落時機的外部物體偵測器，如 Grounding DINO [21]。前者使導航代理人退化為被動的指令執行者。後者讓飛行與降落分屬兩個模組，一旦偵測器在開放場景中失誤，將降低整體系統的穩健性 [6]。AerialVLA [6] 針對此問題提出極簡的 VLA 架構：以 OpenVLA-7B [5] 為骨幹，僅輸入前視與下視兩張影像，經 SigLIP [7] 與 DINOv2 [8] 混合編碼後，搭配僅由機載感測器推得的模糊方向提示，以 LoRA [10] 微調 Llama 2 [9] 語言模型，直接輸出三自由度控制指令的數值 token，並以 LAND token 學習內在停止策略（intrinsic stopping policy）。

在 TravelUAV Benchmark [3] 的 UAV-Need-Help 任務中，AerialVLA [6] 於三個測試集均取得目前最高的 SR。其於已見環境（Seen）的 SR 達 47.96%、SPL 達 38.54%，SR 較依賴歷史上下文的 LongFly [17] 高出 11.57 個百分點。於未見物體（Unseen Object）測試集的 SR 亦達 56.60%。在未見地圖（Unseen Map）中，LongFly 的 SR 降至 11.27%，AerialVLA 仍維持 37.58%，約為其三倍 [6]。AerialVLA 的消融實驗亦顯示，將輸入擴增為五個視角反而使未見地圖 SR 由 37.58% 降至 21.71% [6]，說明單純增加影像輸入會引入背景干擾，新增的視覺資訊必須精簡且與導航任務直接相關。然而，相較於已見環境，AerialVLA 在未見地圖的 SR 與 SPL（28.22%）仍分別減少 10.38 與 10.32 個百分點。此外，未見地圖的 OSR 為 52.92%，與 SR 相差 15.34 個百分點，高於已見環境的 9.73 個百分點 [6]，顯示在陌生環境中，有相當比例的飛行

曾抵達目標附近，卻未能正確判斷停止時機。SR 與 OSR 之間的落差普遍存在於現有 VLN 方法中，且長期未受重視 [22]。人類操作者在已見環境的 SR 則為 94.51% [6]，與模型之間仍有明顯差距。

造成上述落差的可能原因之一，在於 AerialVLA 採取純反應式策略：每一步僅依據當下的單幀觀測做出決策，未使用記憶機制，以壓低推論延遲 [6]。作者亦指出，該模型在結構重複的城市地圖中有時難以進行全域回溯，在目標被濃密樹冠遮蔽時則傾向原地懸停 [6]。單幀靜態影像本身不含無人機移動狀態、與目標的距離變化等時序資訊，模型只能從外觀推斷，且當地圖的外觀分布改變時，便容易失準。

另一方面，AerialVLA 的訓練與評估皆在 AirSim [4] 模擬環境中進行 [6]。模擬畫面的光照、陰影與材質變化通常較真實場景單純，若欲將此技術應用於真實環境時，推測將面臨模擬環境與真實環境場景分布落差。AerialVLA 已先處理落地的兩項前提。其一為推論效率：在 RTX 4090 上的總延遲為 0.38 秒、GPU 記憶體需求 17 GB，低於 TravelUAV 的 0.63 秒與 20 GB [6]。其二為系統整合：其前進、高度與偏航三自由度的動作空間，對應 DJI SDK、PX4 等商用飛控介面的高階指令 [6]，端對端輸出有利於與現有飛控介面整合。因此，推動此技術落地的下一步，在於提升模型於真實場景中的視覺理解能力。

在視覺表徵方面，運動資訊常以光流表示。傳統古典光流法（如 Lucas–Kanade [12]）高度仰賴「亮度恆定假設」（Brightness Constancy Constraint），即假設同一像素在移動過程中顏色與亮度完全保持不變（$\nabla f \cdot v = -\delta f$ ）。然而，在無人機實際飛行過程中，太陽照射角度隨時間轉變、雲層遮蔽或建築物陰影的動態變化，皆會導致畫面像素產生劇烈的亮度波動。傳統光流會將此類純粹的光影變化誤判為物體的劇烈位移，進而產生假運動（false motion）訊號；若直接應用於端對端導航，無人機將誤以為周遭環境或目標建築物正在發生相對位移，導致航向偏離或迷失導航。深度學習方法如 RAFT [13] 精度較高，但需大規模資料訓練與任務特定的最佳化，計算開銷高昂 [16]。

為了解決此問題，ReynoldsFlow [16] 結合雷諾傳輸定理（Reynolds Transport Theorem, RTT）[15] 與亥姆霍茲–霍奇分解（Helmholtz–Hodge Decomposition, HHD）[14]，提出一種受流體力學啟發的物理感知時空流表徵（Physics-Inspired Spatiotemporal Flow Representation），將速度場 $\boldsymbol{v}$ 嚴謹地拆解為兩個具物理可解釋性的獨立運動分量：無旋分量 $\boldsymbol{v}_c$（Curl-Free, CF，滿足旋度 $\nabla \times \boldsymbol{v}_c = 0$）與無散分量 $\boldsymbol{v}_d$（Divergence-Free, DF，滿足散度 $\nabla \cdot \boldsymbol{v}_d = 0$）。其中 $\boldsymbol{v}_c$ 專門用以捕捉畫面區域的膨脹、縮放及光照陰影變化；$\boldsymbol{v}_d$ 則專門捕捉物體真正的剛體平移與旋轉位移。透過免訓練矩陣運算，ReynoldsFlow 建立散度補償機制以扣除光影干擾，並將無散強度 $|\boldsymbol{v}_d|$、無旋強度 $|\boldsymbol{v}_c|$ 與原始影像灰階強度 f^n 組成三通道特徵圖 $\boldsymbol{F}_{\mathrm{R}}^n = [|\boldsymbol{v}_d^n|, |\boldsymbol{v}_c^n|, f^n]$。此表徵完全免訓練，能將運動位移與光照變化有效解耦（技術細節與演算法推導詳見（二）研究方法）。

綜觀現有研究，以 AerialVLA 為代表的端對端 UAV-VLA 模型，每一步僅以當下的單幀影像作為視覺輸入 [6]。具物理意義的運動表徵則多應用於物體偵測、姿態估計等感知任務 [16]，尚未被引入端對端的導航控制。本計畫即針對此一缺口，並進一步評估其在 NE、SR、OSR、SPL、GP 等指標的實際表現與可行性。

基於上述觀察，本計畫的核心研究問題為：能否在不導入記憶緩衝、且不增加推論時長的前提下，為端對端 UAV-VLA 補充對光照變化穩健、且具物理意義的運動資訊，以縮小未見環境與已見環境之間的表現落差，並改善抵達目標後的停止判斷。

在學術與技術指標上，本計畫預期將 ReynoldsFlow 物理運動表徵融入 AerialVLA 後，能有效克服真實或高擬真環境中光影交替對導航感知產生的干擾。我們預期於 TravelUAV 未見地圖（Unseen Map）與未見物體（Unseen Object）測試集上，全面提升以下核心導航指標：

1. **成功率（Success Rate, SR）**與**路徑長度加權成功率（Success weighted by Path Length, SPL）**：透過無散分量 v_d 提供乾淨的轉向與位移線索，避免無人機因光照變化產生「大樓在移動」的假象而走偏，預期能顯著拉升陌生環境下的 SR 與飛行路徑效率 SPL。
2. **導航完備度 / 導航效能（Goal Progress, GP / Navigation Error, NE）**：減少無人機在導航過程中的無效探索與迷航，預期降低導航誤差 NE 並提高朝向目標推進的有效距離（GP）。
3. **Oracle 成功率（Oracle Success Rate, OSR）與停止判斷**：利用無旋分量 v_c 對畫面區域擴張與縮放的敏感度，當無人機接近目標大樓時，畫面中大樓的幾何擴張訊號可作為強烈的內在距離線索，協助模型精準發出 LAND（降落）指令，預期能有效縮小 OSR 與 SR 之間的落差（即解決「飛行曾抵達目標附近卻未能正確停止」的痛點）。

本計畫的原創性在於以下三方面：

1. 就目前文獻所見，本計畫首度將免訓練、具物理可解釋性的運動表徵引入端對端 UAV-VLA，以低成本補足反應式策略所欠缺的時序資訊，而不需導入記憶緩衝。
2. 本計畫以運動分量對應導航決策作為設計假設。無旋分量與畫面擴張相關，可望反映無人機接近目標的程度，輔助停止判斷。無散分量包含旋轉成分，可望反映偏航變化，輔助方向對準。此假設將於本計畫中以實驗驗證。
3. ReynoldsFlow 對光照變化的穩健性 [16]，使本計畫除提升模擬環境中的指標外，也直接回應由模擬移轉至真實場景時的外觀落差。

在學術上，本計畫可檢驗為反應式 VLA 補充物理運動資訊能否改善陌生環境中的導航表現，預期於 TravelUAV 未見地圖測試集上降低 NE、提升 SR 與 SPL，並縮小 OSR 與 SR 之間的差距。消融實驗亦可釐清各運動分量對導航決策的貢獻，提供可解釋的分析。

在應用上，ReynoldsFlow 免訓練且計算成本低 [16]，可望在 AerialVLA 0.38 秒的延遲基礎上維持即時性 [6]。結合其對光照變化的穩健性，本計畫有助於推動 UAV-VLN 由模擬走向真實場景，支援搜救、巡檢等 GPS 訊號不可靠或目標座標未知的任務。

（二）研究方法、進行步驟及執行進度

1. 研究方法與原因及其創新性

本計畫以 AerialVLA [6] 為主要模型，在不改動其三自由度動作空間、模糊方向提示與內在停止策略的前提下，引入 ReynoldsFlow [16] 運動表徵，補充單幀影像所欠缺的時序資訊。選擇 AerialVLA [6]作為基線的原因有三：

1. 其程式碼已公開，便於重現與修改。
2. 其於 TravelUAV 三個測試集均取得目前最高的 SR [6]。
3. 其推論延遲與動作空間已符合落地需求 [6]。

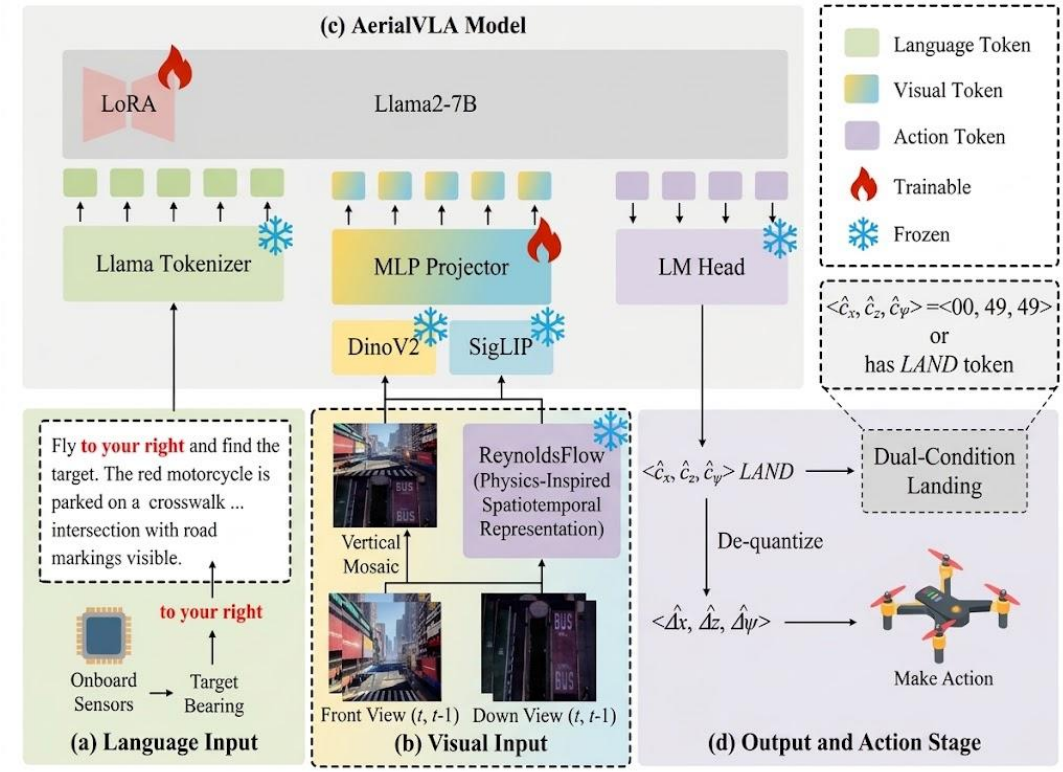


圖 1. 研究流程圖

整體研究流程如圖 1 所示。系統首先讀取無人機當前時間步 t 與前一採樣步 $t-1$ 的前視與下視影像；隨後透過免訓練的 ReynoldsFlow [16] 模組獨立導出前後視角之物理運動表徵 F_R；接著經由本計畫設計之**多模態特徵空間拼接整合架構**與原始視覺特徵對齊併入，輸入至微調後的 OpenVLA-7B 骨幹網絡 [5]；最後解碼直接輸出前進速度、高度改變、偏航角速度等三自由度連續控制指令數值 token，並學習發出 LAND 降落 token。

1.1 資料集與模擬環境

本計畫採用 TravelUAV [3] 的 UAV-Need-Help 任務，依官方切分，以 7,922 條軌跡訓練，並於已見環境（1,418 條）、未見物體（629 條）與未見地圖（958 條）三個測試集評估 [6]。模擬環境採用基於 Unreal Engine 之 AirSim 平台（如圖 2 所示）

[4]，並比照 AerialVLA 設定為 MaxDegreeOfFreedom 模式，使無人機可在前進的同時獨立調整偏航角 [6]。視覺輸入沿用前視與下視兩個 90 度視角，兩者垂直拼接後縮放為 224 x 224 [6]。ReynoldsFlow [16] 需以時間相鄰的兩幀計算，前後幀之取得方式詳見第 2 小節說明。值得注意的是，如圖 2 所示，在 AirSim 高擬真環境中，無人機近距離飛越具備高反射率之表面或大樓時，環境光源會於物體表面產生劇烈的鏡面高光（Specular Highlight）與陰影偏移。此類非剛體的光化學變化將導致傳統光流產生假運動訊號，本計畫即透過 ReynoldsFlow 的物理分量解耦機制，於此類高難度光照場景中維持導航感知之穩健性。

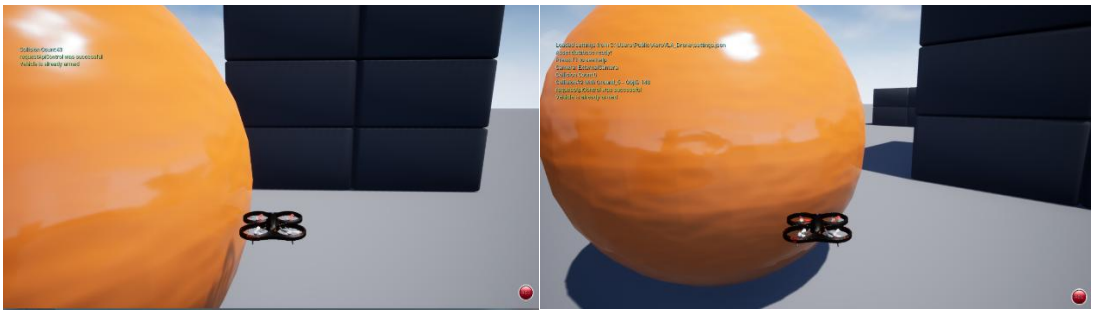


圖 2. AirSim 模擬環境中無人機近距離飛行與強光照反射測試場景示意圖
(左圖) 無人機位移過程，視覺視角劇烈改變，光照與幾何擴張訊號同步波動。
(右圖) 無人機靠近橘色高反射物體，表面呈現強烈高光與背光陰影。

1.2 ReynoldsFlow 運動表徵

本計畫對前視與下視影像分別計算 ReynoldsFlow，將運動場分解為無旋分量 v_c 與無散分量 v_d，並依原作者設計組成三通道表徵 $F_R^n = [|v_d|, |v_c|, f^n]$，其中 f^n 為當前影格之灰階強度 [16]。

在演算推導上，設時間步 t^n 與 t^{n-1} 之影像強度分別為 f^n 與 f^{n-1}。根據雷諾傳輸定理（RTT）[15]，像素強度變化率在演化區域 $\Omega(t)$ 上滿足：

$$\frac{d}{dt}\int_{\Omega(t)} f \, dA = \int_{\Omega(t)} \left(\frac{\partial f}{\partial t} + \nabla f \cdot \boldsymbol{v} + f\nabla \cdot \boldsymbol{v}\right) dA \tag{1}$$

透過亥姆霍茲–霍奇分解（HHD）[14]，運動速度場拆解為滿足 $\nabla \times v_c = 0$ 的無旋分量 v_c 及滿足 $\nabla \cdot v_d = 0$ 的無散分量 v_d（即 $v = v_c + v_d$）。推導過程如下：

1. **無旋分量 $\boldsymbol{v_c}$ 之快速計算**：基於區域變換之雅可比行列式（Jacobian Determinant）$dA^n \approx (1 + \nabla \cdot v^n \Delta t) dA^{n-1}$。將離散時間差 $\delta f^n = f^n - f^{n-1}$ 與連續項對齊後經分部積分導出變分形式。此變分式無需進行複雜疊代，僅需透過 3×3 的局部滑動視窗（Window Patch）計算邊界能量通量與內部梯度的差值，再經高斯平滑核 G 濾波處理，即可直接分離出由光照與幾何擴散引起的速度場：

$$\boldsymbol{v_c^n} = \begin{bmatrix} G * ((\delta f_b^n)_x - (\nabla \delta f_\omega^n)_x) \\ G * \left((\delta f_b^n)_y - (\nabla \delta f_\omega^n)_y\right) \end{bmatrix} \tag{2}$$

2. **無散分量 v_d 之求解與散度補償**：導出散度補償殘差圖 D 以扣除純光影與幾何縮放的干擾：

$$D = -\delta f^n - \nabla f^n \cdot v_c^n - f^n \nabla \cdot v_c^n \tag{3}$$

隨後將乾淨殘差 D 代入 Lucas–Kanade [12] 加權最小平放大矩陣中：

$$\begin{bmatrix} \Sigma W (f_x^n)^2 & \Sigma W f_x^n f_y^n \\ \Sigma W f_x^n f_y^n & \Sigma W (f_y^n)^2 \end{bmatrix} \begin{bmatrix} u_d \\ v_d \end{bmatrix} = \begin{bmatrix} \Sigma W f_x^n D \\ \Sigma W f_y^n D \end{bmatrix} \tag{4}$$

求解逆矩陣後即可獲得排除光影干擾後的真實平移與旋轉速度場 $v_d = (u_d, v_d)^\top$。

此物理表徵免訓練，且保留影像強度資訊，可與原有的影像輸入在空間上對齊。由於 AerialVLA [6] 以每秒 1 公尺的固定巡航速度執行動作，不同時間步的運動量級具可比性，有助於模型學習運動強度與距離變化之間的關係。

1.3 整合方案

AerialVLA [6] 的消融實驗顯示，若單純增加視角輸入會引入背景干擾，使未見地圖 SR 由 37.58% 降至 21.71%。因此，新增的視覺資訊必須與導航任務直接相關且精簡。本計畫採用「多模態特徵空間拼接（Multimodal Spatial Concatenation）」作為核心整合方案。

具體實作上，系統將前視與下視影像經由 ReynoldsFlow 計算獲得之物理運動特徵圖 $\boldsymbol{F}_{\mathrm{R}} = [|\boldsymbol{v}_d|, |\boldsymbol{v}_c|, f^n]$，與當前時間步 t 之原始 RGB 拼接影像（Vertical Mosaic）在空間維度進行組合拼接，作為統一的視覺表徵輸入送入原有的 SigLIP 與 DINOv2 視覺編碼器。此方案之主要優勢在於無需修改模型之主幹神經網絡架構與 token 序列長度，實作與部署成本最低，且能在不增加額外模型參數與顯存負擔的前提下，使預訓練視覺編碼器同時獲取靜態外觀與動態物理運動資訊。

1.4 訓練設定

本計畫第一步為重現 AerialVLA [6]的基線結果，作為後續比較的依據。訓練設定沿用原論文：以 OpenVLA-7B [5] 為骨幹，於 Llama 2 [9] 上套用 LoRA [10]（$r = 64$、$\alpha = 128$、dropout 0.05），凍結視覺編碼器並完整微調投影層，以行為複製（behavior cloning）為訓練目標，最小化專家動作 token 的負對數概似 [6]。最佳化器採用 AdamW，搭配餘弦學習率排程，峰值學習率為 2×10^{-4} [6]。原論文以 4 張 RTX 4090 訓練 5 個 epoch，約需 35 小時 [6]，本計畫將以此估算各方案的計算需求。各整合方案除新增模組外，其餘設定皆與基線一致，以確保比較公平。

1.5 評估指標與實驗設計

評估指標沿用 TravelUAV 的標準設定 [3,6]。令 N 為測試軌跡數，$p_i(t)$ 為第 i 條軌跡

在時間 t 的位置，T_i 為停止時間，g_i 為目標位置，$d(\cdot,\cdot)$ 為歐氏距離，各指標定義如下：

$$\mathrm{NE} = \frac{1}{N}\sum_{i=1}^{N} d\left(p_i(T_i), g_i\right) \tag{5}$$

$$\mathrm{SR} = \frac{1}{N}\sum_{i=1}^{N} 1\left[d(p_i(T_i), g_i) \le 20\ \mathrm{m}\right] \tag{6}$$

$$\mathrm{OSR} = \frac{1}{N}\sum_{i=1}^{N} 1\left[\min_t d(p_i(t), g_i) \le 20\ \mathrm{m})\right] \tag{7}$$

$$\mathrm{SPL} = \frac{1}{N}\sum_{i=1}^{N} \frac{S_i \cdot \ell_i}{\max(L_i, \ell_i)} \tag{8}$$

其中 $1[\cdot]$ 為指示函數，S_i 表示第 i 條軌跡是否成功，ℓ_i為起點至目標的最短路徑長度，L_i 為實際飛行路徑長度 [11]。NE 越低越好，SR、OSR 與 SPL 越高越好。此外，本計畫亦將 OSR 與 SR 的差距作為停止判斷能力的觀察指標，並包含 Goal Progress（GP）評估推進有效性。

實驗分兩階段進行：

- **第一階段（端對端導航效能評估）**：比較原始 AerialVLA 基線模型與融入 ReynoldsFlow 運動特徵拼接模型，於已見環境、未見物體與未見地圖三個測試集上報告 NE、SR、OSR、SPL、GP 及單步推論延遲，驗證物理運動資訊對連續導航與停止策略之整體提升。
- **第二階段（物理運動分量消融實驗）**：針對 ReynoldsFlow 模型進行分量消融，比較僅使用無旋分量（$\boldsymbol{v}_c$）、僅使用無散分量（$\boldsymbol{v}_d$）與同時使用兩者的結果，以檢驗研究背景中的兩項設計假設：
    1. 無旋分量（$\boldsymbol{v}_c$）是否主要改善停止判斷，反映於 OSR 與 SR 差距的縮小。
    2. 無散分量（$\boldsymbol{v}_d$）是否主要改善方向對準，反映於 SPL 的提升。

此外，為檢驗運動表徵對光照變化的穩健性，本計畫將利用 AirSim 的時段與天氣設定，建立不同光照條件的測試情境，比較基線與選出方案在各情境下 SR 與 SPL 的下降幅度，作為評估由模擬移轉至真實場景潛力的參考。

本計畫方法的創新性在於以下三點：

1. 以免訓練的運動表徵補充時序資訊，不需修改 AerialVLA 的動作空間與訓練目標，也不需導入記憶緩衝。
2. 提出物理運動表徵與視覺語言動作模型（VLA）之無縫拼接融合機制，為 UAV-VLA 導入物理感知資訊提供極低開銷的設計依據。
3. 透過分量消融，將導航表現的變化對應至具物理意義的運動分量，提升模型行為的可解釋性。

2. 預計可能遭遇之困難及解決途徑

第一，運動表徵與預訓練編碼器的分布不符。SigLIP 與 DINOv2 編碼器以自然影像預訓練，且於 AerialVLA 中保持凍結，運動表徵的統計特性與自然影像不同。解決途徑包括：

1. ReynoldsFlow 表徵本身保留了原始影像強度通道f^n，可有效降低與預訓練編碼器的分布差異。
2. 若特徵擷取效果仍有不足，本計畫將對視覺編碼器與 MLP Projector 之間的連接層套用 LoRA 進行輕量微調。

第二，無人機自身運動主導光流。無人機飛行時，畫面中大部分的運動來自自身移動，而非場景中的物體。由於本計畫所需的正是自身運動造成的畫面擴張與旋轉，此特性對停止判斷與方向對準有利。然而，目標附近的局部運動線索可能被整體運動掩蓋。對此，本計畫的對策包括：

1. 比較前視與下視運動表徵各自的貢獻。
2. 觀察下視畫面在降落階段的擴張訊號。
3. 保留原有的影像路徑，使模型可結合外觀與運動資訊進行目標定位。

第三，相鄰兩步的位移過大。AerialVLA 每一步的前進位移最大可達 5 公尺，偏航角變化可達 $\pm\pi$ [6]，若僅以相鄰兩步的觀測計算運動表徵，畫面差異可能超出光流的小位移假設。由於 AerialVLA 以每秒 1 公尺的固定速度執行每一步 [6]，本計畫將於執行過程中取樣中間影格，以時間間隔較短的兩幀計算運動表徵。若訓練資料僅保存各步的觀測，則於 AirSim 中依專家軌跡重播，補取對應的中間影格。

第四，推論延遲增加。AerialVLA 的單步總延遲為 0.38 秒，新增的運動表徵計算可能增加些許延遲。然而，ReynoldsFlow 主要由 3X3 卷積與局部最小平方運算組成，全過程皆可於 GPU 上高度平行化處理。本計畫將精確量測運動特徵算子之額外開銷，確保單步總延遲仍維持在即時控制範圍（＜0.4 秒）內。

（三）預期完成之工作項目及成果

1. 預期完成之工作項目

本計畫為一年期計畫，預期完成以下工作項目：

(1) 重現 AerialVLA 於 TravelUAV UAV-Need-Help 任務之基線結果，建立後續比較之依據。
(2) 建立 ReynoldsFlow 運動表徵計算管線，包含前視與下視影像之運動分量計算，以及中間影格之取樣流程。
(3) 實作 ReynoldsFlow 物理運動特徵與 AerialVLA 視覺輸入之空間拼接整合管線，於三個測試集上完成導航效能評估。
(4) 針對空間拼接整合模型完成運動分量消融實驗，檢驗無旋分量與無散分量對停止判斷及方向對準之影響。
(5) 完成不同光照條件下之穩健性測試，以及本模型與基線模型之推論延遲量測。
(6) 整理實驗結果，撰寫學術論文與計畫成果報告。

2. 參與之工作人員預期可獲之訓練

- 碩士生訓練目標：
  (1) 熟悉 AirSim 模擬環境操作與 TravelUAV 資料處理流程，具備無人機導航資料之蒐集與整理能力。
  (2) 掌握大型 VLA 模型之 LoRA 微調技術，負責基線重現與各整合方案之實驗執行。
  (3) 完成文獻整理與實驗紀錄，協助撰寫國際研討會論文初稿。

- 博士生訓練目標：
  (1) 主導運動表徵與 VLA 模型之整合架構設計，培養跨領域之模型設計能力。
  (2) 負責實驗設計與結果分析，透過分量消融培養模型行為之可解釋性分析能力。
  (3) 統籌撰寫學術論文與技術報告，負責期刊論文投稿與計畫成果整理。

3. 預期完成之研究成果

(1) 完成一套結合 ReynoldsFlow 運動表徵之端對端 UAV-VLN 模型，預期於 TravelUAV 未見地圖測試集上降低 NE、提升 SR、SPL 與 GP，並縮小 OSR 與 SR 之差距。
(2) 提出物理運動表徵與視覺語言動作模型（VLA）之無縫拼接融合機制，作為 UAV-VLA 新增運動資訊之設計依據。
(3) 預期將研究成果整理投稿至國際研討會（如 CVPR/ICCV/ROBIO）與 SCI 期刊（如 IEEE T-RO 或 RAL）。
(4) 論文經國際期刊接受後，將公開程式碼與實驗設定，便於後續研究重現與延伸。
(5) 完成計畫成果報告一份。

4. 學術研究、國家發展及其他應用方面預期之貢獻

4.1 學術貢獻

(1) 就目前文獻所見，首度將免訓練、具物理可解釋性之運動表徵引入端對端 UAV-VLA，驗證不需導入記憶緩衝即可補充時序資訊之可行性。
(2) 透過運動分量消融，將導航表現之變化對應至具物理意義之運動分量，為 VLA 模型提供可解釋之分析方法。
(3) 針對 SR 與 OSR 之落差此一 VLN 領域普遍存在之問題 [22]，提出以運動資訊改善停止判斷之研究方向。

4.2 國家發展與實務應用貢獻

(1) 推動 UAV-VLN 技術由模擬走向真實場景，支援搜救、基礎設施巡檢等 GPS 訊號不穩定或目標座標未知之任務。

(2) 維持 AerialVLA 之低延遲特性，且其動作空間對應 DJI SDK、PX4 等商用飛控介面 [6]，有利於與實際無人機應用場域之整合。

(3) 培養兼具視覺語言模型、無人機控制與物理啟發視覺表徵之跨領域人才。

（四）參考文獻

[1] P. Anderson, Q. Wu, D. Teney, J. Bruce, M. Johnson, N. Sünderhauf, I. Reid, S. Gould, and A. van den Hengel, "Vision-and-language navigation: Interpreting visually-grounded navigation instructions in real environments," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2018, pp. 3674–3683.

[2] S. Liu, H. Zhang, Y. Qi, P. Wang, Y. Zhang, and Q. Wu, "AerialVLN: Vision-and-language navigation for UAVs," in Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 2023, pp. 15384–15394.

[3] X. Wang, D. Yang, Z. Wang, H. Kwan, J. Chen, W. Wu, H. Li, Y. Liao, and S. Liu, "Towards realistic UAV vision-language navigation: Platform, benchmark, and methodology," in Proc. Int. Conf. Learn. Represent. (ICLR), 2025.

[4] S. Shah, D. Dey, C. Lovett, and A. Kapoor, "AirSim: High-fidelity visual and physical simulation for autonomous vehicles," in Field and Service Robotics, Springer, 2018, pp. 621–635.

[5] M. J. Kim et al., "OpenVLA: An open-source vision-language-action model," in Proc. Conf. Robot Learn. (CoRL), 2024.

[6] P. Xu, Z. Deng, J. Deng, Z. Gu, and S. Wan, "AerialVLA: A vision-language-action model for UAV navigation via minimalist end-to-end control," arXiv preprint arXiv:2603.14363, 2026.

[7] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, "Sigmoid loss for language image pre-training," in Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 2023, pp. 11975–11986.

[8] M. Oquab et al., "DINOv2: Learning robust visual features without supervision," Trans. Mach. Learn. Res. (TMLR), 2024.

[9] H. Touvron et al., "Llama 2: Open foundation and fine-tuned chat models," arXiv preprint arXiv:2307.09288, 2023.

[10] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," in Proc. Int. Conf. Learn. Represent. (ICLR), 2022.

[11] P. Anderson et al., "On evaluation of embodied navigation agents," arXiv preprint arXiv:1807.06757, 2018.

[12] B. D. Lucas and T. Kanade, "An iterative image registration technique with an application to stereo vision," in Proc. Int. Joint Conf. Artif. Intell. (IJCAI), 1981, pp. 674–679.

[13] Z. Teed and J. Deng, "RAFT: Recurrent all-pairs field transforms for optical flow," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2020, pp. 402–419.

[14] H. Bhatia, G. Norgard, V. Pascucci, and P.-T. Bremer, "The Helmholtz-Hodge decomposition—A survey," IEEE Trans. Vis. Comput. Graph., vol. 19, no. 8, pp. 1386–1404, Aug. 2013.

[15] F. M. White, Fluid Mechanics, 7th ed. New York, NY, USA: McGraw-Hill, 2011, ch. 3, pp. 132–138.

[16] Y.-H. Chen, C.-K. Lin, P. Huang, and C.-T. Wu, "ReynoldsFlow: Physics-inspired spatiotemporal flow representation for video understanding," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2026.
[17] W. Jiang, L. Wang, K. Huang, W. Fan, J. Liu, S. Liu, H. Duan, B. Xu, and X. Ji, "LongFly: Long-horizon UAV vision-and-language navigation with spatiotemporal context integration," arXiv preprint arXiv:2512.22010, 2025.
[18] J. Zhang et al., "Embodied navigation foundation model," in Proc. Int. Conf. Learn. Represent. (ICLR), 2026.
[19] V. Serpiva, A. Lykov, A. Myshlyaev, M. H. Khan, A. A. Abdulkarim, O. Sautenkov, and D. Tsetserukou, "RaceVLA: VLA-based racing drone navigation with human-like behaviour," arXiv preprint arXiv:2503.02572, 2025.
[20] B. Zitkovich et al., "RT-2: Vision-language-action models transfer web knowledge to robotic control," in Proc. Conf. Robot Learn. (CoRL), 2023.
[21] S. Liu et al., "Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2024, pp. 38–55.
[22] C. Zhao et al., "Mind the gap: Improving success rate of vision-and-language navigation by revisiting oracle success routes," in Proc. ACM Int. Conf. Multimedia (ACM MM), 2023, pp. 4930–4939.