財政部關務署臺北關

「次世代人工智慧輔助緝私計畫」

案號：113052

114年度1-1 研究及發展生成AI

影像研究報告

第3版

文件編號：CATC1-010T-03

中華民國：115年月日

文件修訂紀錄表

版次	日期	變更（原）頁次	制／修訂人員
第3版	115年月日	以下空白	以下空白

Contents

文件修訂紀錄表 **1**

1 生成式第一題 **3**

1.1 製造球：可微分X 光轉換器 4

1.2 把球塑形：對抗性形狀優化 4

1.3 球要放哪裡：攻擊位置强化 5

1.3.1 梯度公式 5

1.3.2 獎勵公式 5

2 結果 **6**

1 生成式第一題

違禁品樣本稀缺與視角死角：現行2D 擷取技術導致AI 模型僅能學習單一視角，當走私物於行李內旋轉或傾斜時極易產生漏判。

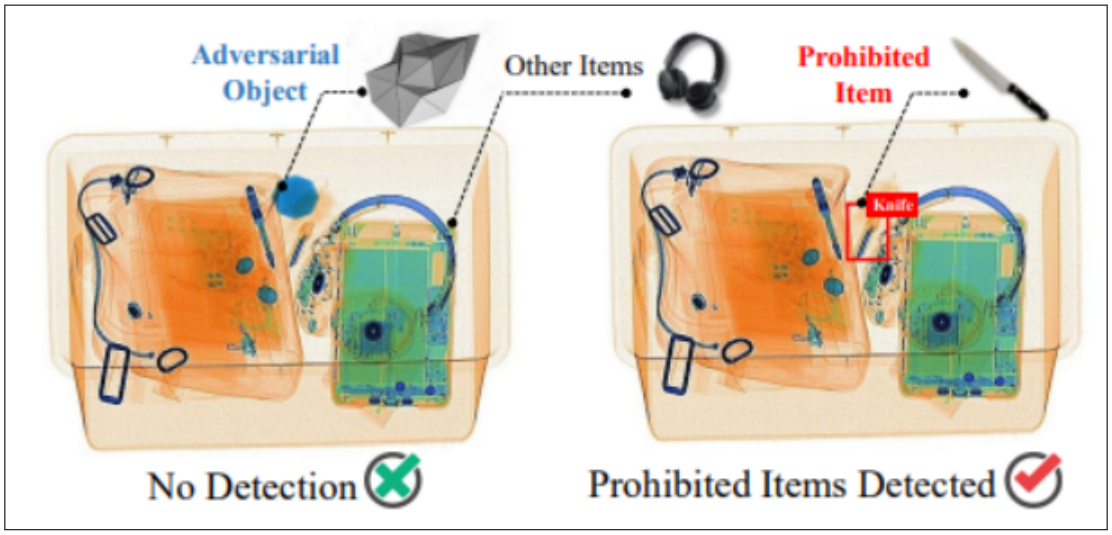


Figure 1: 上圖是在說左圖加一個藍色的立體球，就可以騙過海關的異常偵測感測器了

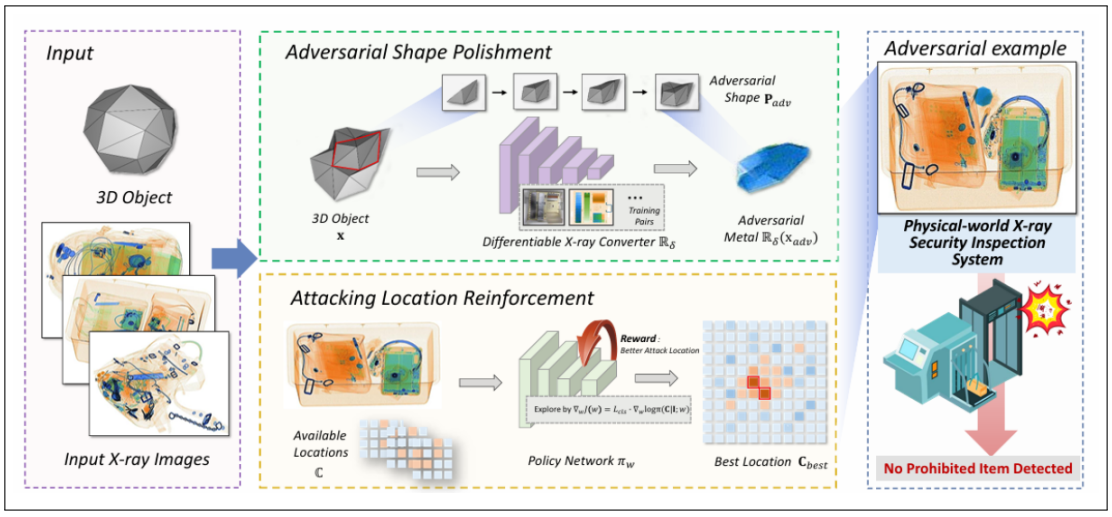


Figure 2: 對抗性X 光安檢影像生成與位置强化流程示意圖

相關研究指出[1]，現行的X 光安檢AI 系統雖然在偵測明顯違禁品方面表現優異，但仍存在被「對抗性攻擊」欺騙的潛在風險。圖2 說明一個由3D 物體輸入、可微分X 光轉換器、對抗性形狀優化、攻擊位置强化與最終安檢系統測試所組成的流程。

1.1 製造球：可微分X 光轉換器

可微分X 光轉換器可將3D 物體的厚度與材質轉換為2D X 光影像中的像素呈現。其簡化形式如下：

$$g_m(d) = a \cdot \exp(-b \cdot d) + q. \tag{1}$$

式(1) 中各符號意義如下：

d：3D 物體的厚度（深度）。

m：物體的材質，例如鐵、鋁、塑膠。

$g_m(d)$：該材質在特定厚度下，轉換出來的X 光影像顏色像素值。

a, b, q：與材質m 相關的係數，用於模擬X 光機掃描不同厚度金屬時的成像變化。

1.2 把球塑形：對抗性形狀優化

對抗性形狀優化（Adversarial Shape Polishment）的目的，是調整3D 物體外觀，使其在經過X 光轉換後，能最大化目標偵測模型的分類錯誤。其目標式可表示為：

$$\mathcal{L}_{adv}\big(\mathbf{X}, \mathbf{x}_{adv}; f_\Theta, \mathbb{R}_\delta\big) = \arg\max_{\mathbf{P}} \mathcal{L}_{cls}\Big(f_\Theta\big(\mathbb{R}_\delta(\mathbf{X}, \mathbf{x}_{adv}^{\mathbf{P}})\big), \{\mathbf{y}_k, \mathbf{b}_k\}\Big). \tag{2}$$

式(2) 中各符號意義如下：

$\mathbf{X}$：原始背景，即行李箱原本的乾淨X 光影像。

$\mathbf{x}_{adv}$：對抗物體（Adversarial object），例如生成的3D 金屬塊。

$\mathbf{P}$：形狀特徵（Shape），具體來說是3D 物體的頂點座標（Vertices）。改變$\mathbf{P}$ 就是在改變物體外觀。

$\mathbf{x}_{adv}^{\mathbf{P}}$：帶有特定形狀的對抗物體，即外觀已經被捏成$\mathbf{P}$ 形狀的3D 金屬塊。

f_Θ：目標偵測器（Target detector），代表欲欺騙的安檢AI 模型；Θ 為模型內部已訓練完成的權重參數。

$\mathbb{R}_\delta$：可微分X 光轉換器（Differentiable X-ray converter），將3D 物體轉換成2D 影像的函數，也可視為前一階段公式的系統化代稱。

$\mathcal{L}_{cls}$：分類損失函數（Classification loss），用於評估AI 將違禁品辨識錯誤的程度。損失越大，代表AI 錯誤越嚴重。

$\mathbf{y}_k, \mathbf{b}_k$：標準答案（Ground truth），其中$\mathbf{y}_k$ 是正確物品名稱或標籤，$\mathbf{b}_k$ 是正確框線

位置（Bounding box）。

$\arg\max_{\mathbf{P}}$：求最大值的引數，表示尋找一個形狀$\mathbf{P}$，使後方分類損失達到最大。

1.3 球要放哪裡：攻擊位置强化

在形狀經過優化後，仍需決定對抗物體應放置於行李箱影像中的哪個2D 座標位置。此階段可透過策略網路（Policy network）進行位置選擇，並使用强化學習方式調整其參數。

1.3.1 梯度公式

$$\nabla_{\mathbf{w}} J(\mathbf{w}) = G \cdot \nabla_{\mathbf{w}} \log \pi(\mathbf{C} \mid \mathbf{I}; \mathbf{w}). \tag{3}$$

1.3.2 獎勵公式

$$G = \mathcal{L}_{cls}\Big(f_{\Theta}\big(\mathbb{R}_{\delta}(\mathbf{X}, \mathbf{x}_{adv}^{\mathbf{P}_{ori},\mathbf{C}})\big), \{\mathbf{y}_k, \mathbf{b}_k\}\Big) + \alpha \cdot \sigma_{\mathbf{C}}. \tag{4}$$

式(3) 與式(4) 中各符號意義如下：

$\mathbf{C}$：攻擊位置（Attacking location），代表對抗物體要放在行李箱畫面中的2D 座標位置。

$\mathbf{x}_{adv}^{\mathbf{P}_{ori},\mathbf{C}}$：特定狀態的對抗物體，形狀維持初始狀態$\mathbf{P}_{ori}$，並且放在座標$\mathbf{C}$ 上。

π：策略網路（Policy network），專門用來預測或選擇攻擊位置的輔助AI 網路。

$\mathbf{w}$：策略網路的參數，即此位置選擇AI 的內部權重。

$\mathbf{I}$：輸入影像（Input image），即提供給策略網路觀察的原始X 光圖。

$\pi(\mathbf{C} \mid \mathbf{I}; \mathbf{w})$：選擇機率，表示策略網路在看到行李箱影像$\mathbf{I}$ 時，決定將物體放在座標$\mathbf{C}$ 的機率。

$J(\mathbf{w})$：目標函數（Objective function），代表策略網路欲最佳化的整體目標。

$\nabla_{\mathbf{w}}$：梯度（Gradient），表示對權重$\mathbf{w}$ 求偏導數，用於描述權重調整方向。

G：獎勵（Reward），為强化學習中的分數；若放置於位置$\mathbf{C}$ 的攻擊效果佳，則G 的分數會較高。

$\mathbf{P}_{ori}$：初始形狀（Initial shape），即對抗物體一開始未經打磨的形狀。

$\sigma_{\mathbf{C}}$：位置標準差（Standard variance of locations），用於衡量AI 選擇位置的多樣性。數值越大，代表AI 嘗試的位置越不重複。

α：平衡係數，用於平衡「攻擊威力」與「位置多樣性」。

2 結果

實驗結果如圖3 所示。在標準未受攻擊的乾淨影像（Clean mAP）情況下，安檢模型的平均精度均值（mAP）可達74.02%。若受到一般基準攻擊（Vanilla），mAP 降至62.77%。然而，若遭遇文獻[1] 所提之對抗性物體攻擊（X-Adv），模型的mAP 會大幅衰退至23.05%。此數據表明，結合形狀優化與位置强化的實體對抗攻擊，能顯著降低並規避現行X 光安檢模型的偵測能力。

Table 1: (mAP)

(Clean mAP)	Vanilla	X-Adv
74.02%	62.77%	23.05%

Figure 3: 不同攻擊條件對安檢模型平均精度均值（mAP）之影響比較

参考文献

[1] A. Liu, J. Guo, J. Wang, S. Liang, R. Tao, W. Zhou, C. Liu, X. Liu, and D. Tao, "X-Adv: Physical Adversarial Object Attacks against X-ray Prohibited Item Detection," *USENIX Security Symposium*, 2023.