聽音辨陰陽
COVID-19 咳嗽音訊辨識之效能評估

機器學習言演算法與應用

第三組
王麒勛、廖意欣、呂錡欣、楊苜庭
吳沛馨、廖筱君、謝易晉、洪浚祐

選擇動機



傳統鼻腔快篩

- 侵入式採樣
- 易造成不適與疼痛
- 步驟繁瑣
- 對頻繁檢測者不便



AI聲音輔助篩檢

- 非侵入式零接觸
- 快速且方便
- 降低人力與時間成本
- 適合遠距與持續追蹤

尋找更溫和的篩檢方式

Nemo marblenet



MFCC
Feature Extraction

+

SVM
Feature Extraction

資料集介紹

COUGHVID dataset

(Larxel, 2021)

自我申報資料 + 10秒內錄音檔

- 日期時間*
- 性別/年齡
- 呼吸系統疾病
- 發燒_肌肉疼痛
- 健康狀況
- 經緯度

- 檢測是否為咳嗽*
- 訊號雜訊比*
- 專家標籤

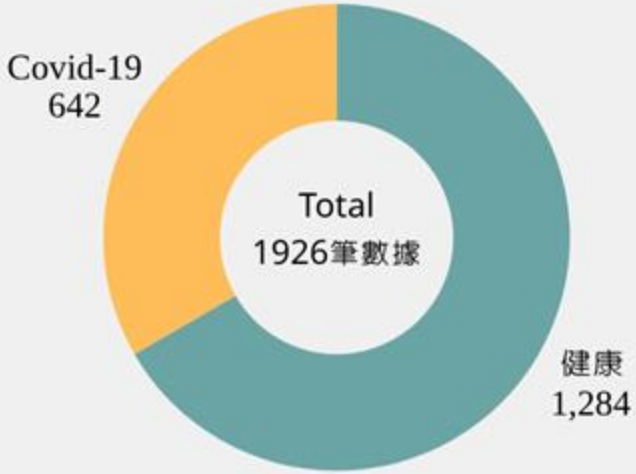
原始資料總數 ：25000筆

經醫生標註：2800筆

uuid	datetime	cough_detected	SNR	latitude	longitude	age	gender	ratory_conc	r_muscle_	status
5d-4847-9ccf-c	13T22:23:06.9975	0.9968	13.14650178			21	male	FALSE	FALSE	healthy
4d-4921-9297-8	17T15:24:35.8223	0.0735	23.01471472	40.6	-3.6					
af-4edb-98ba-b	13T01:27:42.5527	0.0306	12.71348	13.8	-89.6		female	FALSE	TRUE	COVID-19
1c-4029-b33c-d	18T15:11:02.1066	0.7811	12.56640553	45.7	4.9	20	male	TRUE	FALSE	healthy

資料預處理

- 移除咳嗽機率 < 80% 的環境雜音檔案
- 保留15%以上訊號雜訊比以過濾劣質錄音
- 剔除診斷模糊的「 有症狀但未確診者 」



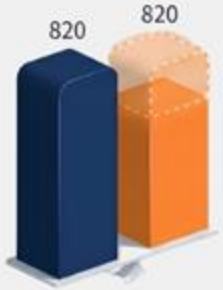
數據不平衡處理

過取樣

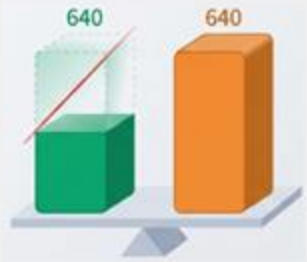
- 合成擴充
  健康：Covid-19＝820 : 820

欠取樣

- 策略性縮減
  健康：Covid-19＝640 : 640



Oversamplling



undersampling

確保模型泛化能力：資料分割策略

重建平衡後的聲學資料庫，將嚴格遵循以下黃金比例進行分割，徹底杜絕數據污染：



端到端 (End-to-End) 疾病預測技術管線

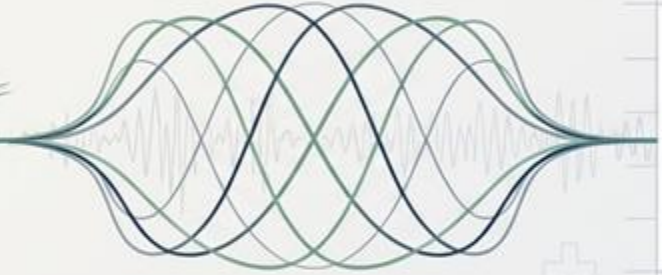


核心技術：為何選擇 MFCC (梅爾頻率倒譜系數)？

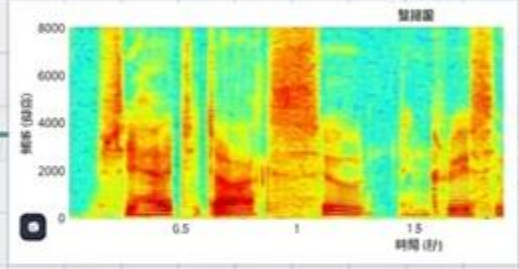
人類聽覺系統



非線性頻率映射



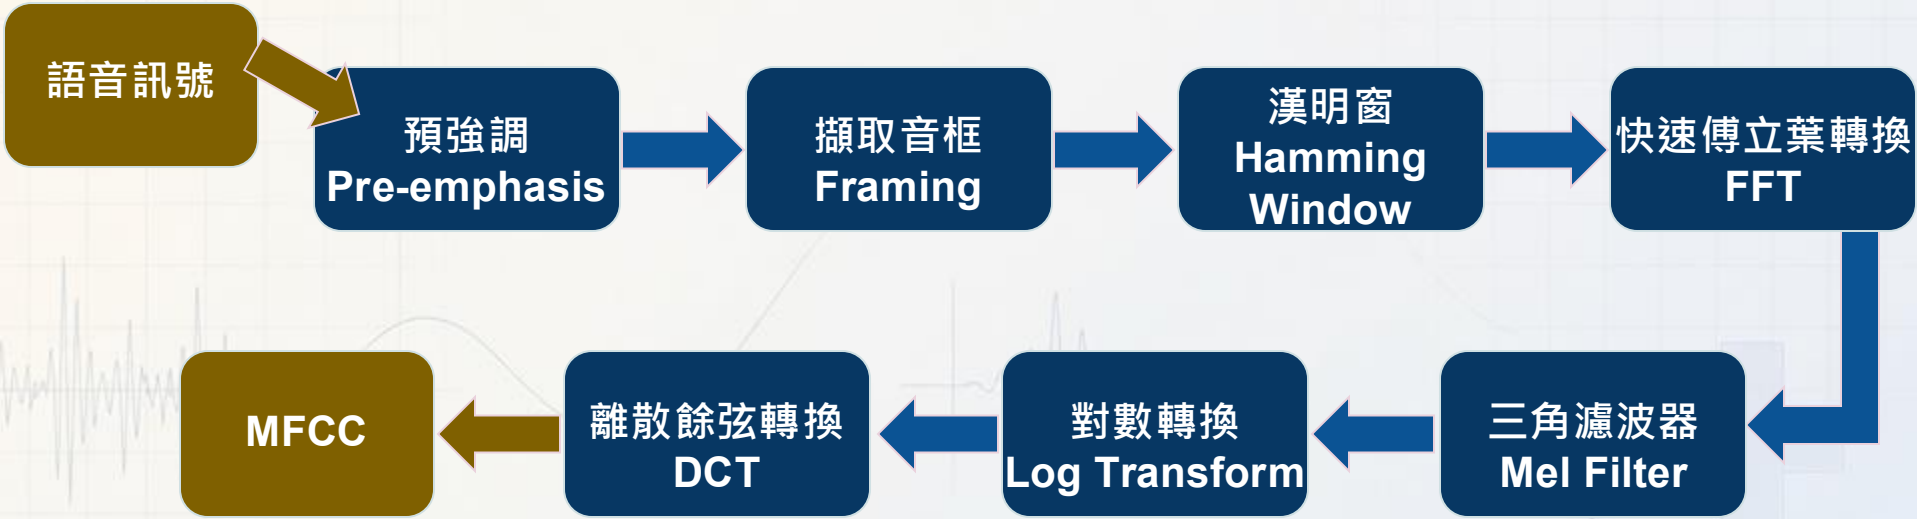
聲譜圖



MFCC 的核心價值在於『**模擬人耳聽覺特性**』。它能非線性地映射聲音頻率，精準捕捉**人類聽覺最敏感的頻段特徵**，從而有效**分離**咳嗽聲中的**病理特徵**與無效雜訊。

MFCC聲學特徵提取流程

- **Mel-Frequency Cepstral Coefficients, MFCC：模擬人耳朵所聽到聲音去提取特徵。**



Step 1. 預強調 (Pre-emphasis)：補償高頻衰減

為什麼需要預強調？

人聲與咳嗽聲在空氣傳遞時，高頻部分的能量往往會自然衰減（稱為頻譜傾斜）。為了讓 AI 模型能清晰捕捉到隱藏在高頻段的病理特徵，我們必須在第一步進行能量補償。

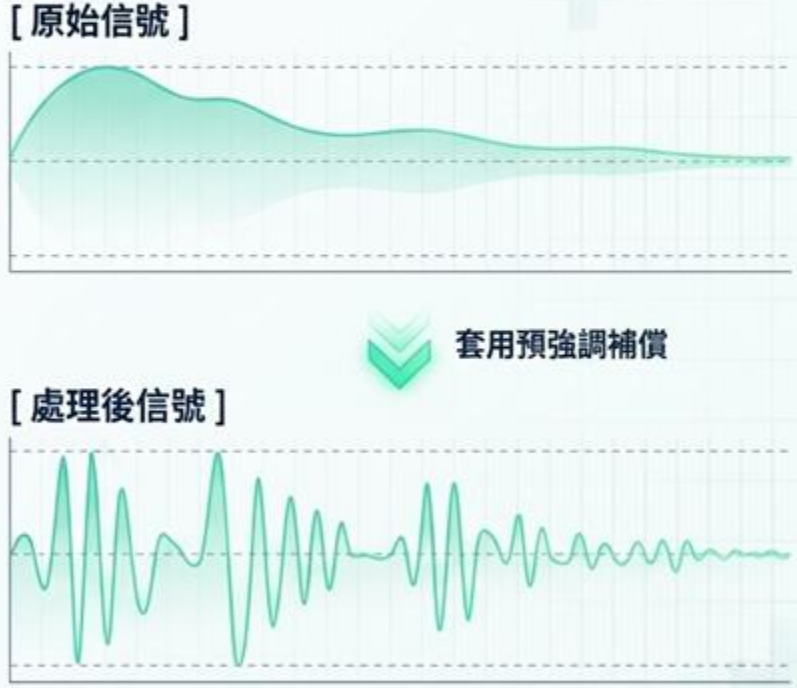
核心演算法

透過一個簡單的一階高通濾波器，強化當前訊號與前一訊號的差異。

$$y(t) = x(t) - \alpha x(t-1)$$

$y(t)$	：預加重後的新信號
$x(t)$	：原始信號當前樣本值
$x(t-1)$	：原始信號前一個樣本值
α	：預加重係數（通常設定在 0.95 ~ 0.97 之間）

訊號增強對比示意



Step 2. 擷取音框 (Framing)：凝結瞬間的聲音特徵

聲音的微觀切片

聲音是隨時間快速變化的連續訊號。為了進行穩定的頻率分析，我們假設在極短的時間內（例如 20-30 毫秒），語音訊號是處於「平穩狀態」的。因此，需要將長訊號切割成無數個短暫的「音框 (Frame)」。

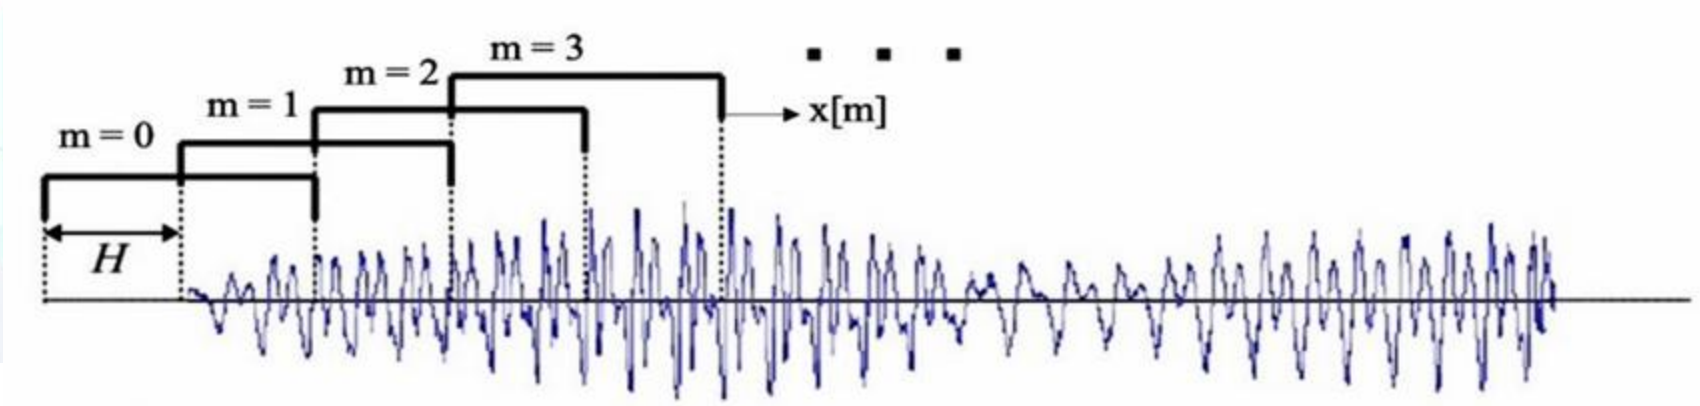
音框索引公式

$$x[m] = \text{Signal}[m \cdot H : m \cdot H + L - 1]$$

L：每個音框的固定長度（例如 256 樣本）
m：音框索引（0, 1, 2...）
H：音框間的平移步長（Hop Size）

為什麼需要 50% 重疊？

如果直接切斷，相鄰音框的邊界會遺漏連續特徵。設定 $H = L/2$，讓前後音框產生重疊，能確保特徵平滑過渡。



Step 3. 漢明窗 (Hamming Window)：消除邊緣的突兀斷裂

⚙ 解決「頻譜洩漏」問題

強行將連續聲音切成音框，會導致波形在兩端出現不自然的垂直斷崖。如果直接轉換，會產生假性高頻雜訊。我們透過乘上「漢明窗」函數，讓音框兩端平滑地衰減至零。

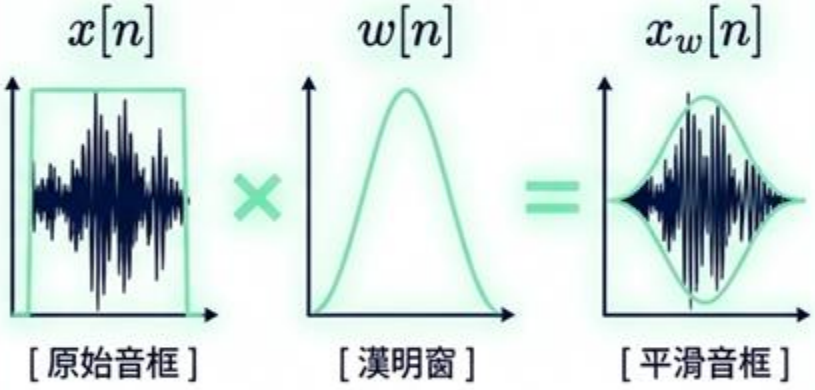
窗函數權重公式

$$w[n] = 0.54 - 0.46\cos\left(\frac{2\pi n}{N-1}\right)$$

$$x_w[n] = x[n] \cdot w[n]$$

$w[n]$：窗函數在第 n 個點的權重值
N：音框的總樣本長度
n：音框內的樣本索引

🖩 邊緣平滑化作用示意



Step 4. 快速傅立葉轉換 (FFT)：解碼隱藏的頻率密碼

咳嗽聲在時間軸上看起來是一團混亂的震盪，但透過 FFT，我們能將其「解壓縮」，拆解成不同頻率的正弦波波組合，找出聲音的真實組成成分。

$$P = \frac{|FFT(x_i)|^2}{N}$$

P：頻譜能量 (Power Spectrum)
$|FFT(x_i)|^2$：經轉換後的複數幅度平方
N：音框的長度

Domain Transformation



時間域 (Time Domain)

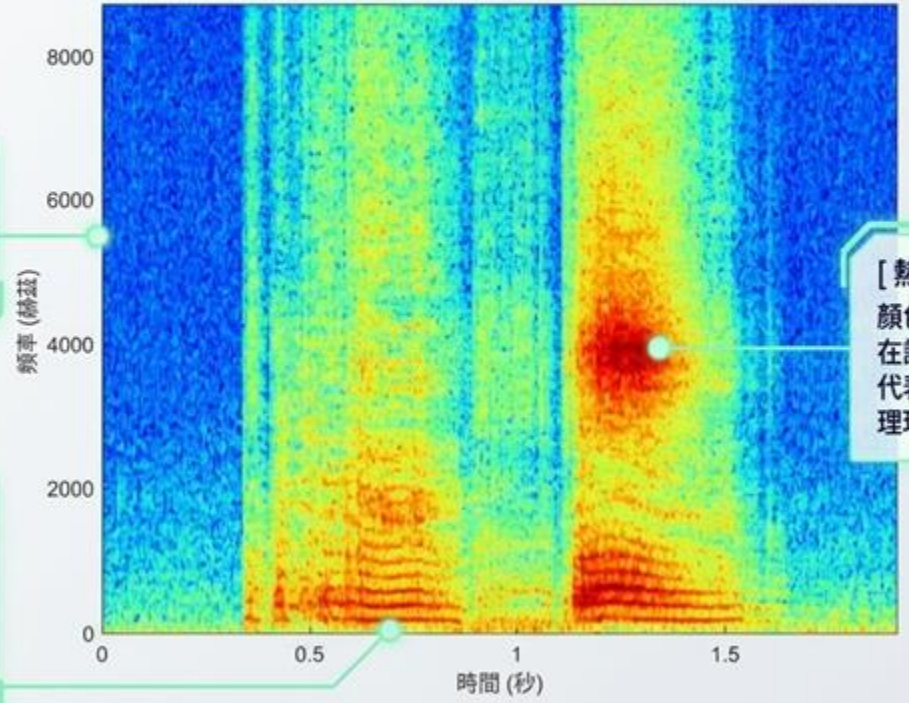
頻率域 (Frequency Domain)

Step 5. 轉頻譜圖 (Spectrogram)：繪製聲音的專屬指紋

單一音框的 FFT 只能看見一瞬間。我們將成千上萬個音框的 FFT 結果依照時間拼接，並將能量大小轉換為矗顏色深淺，誕生出聲音的終極視覺特徵。

[垂直 Y 軸] 頻率 (Frequency)

聲音的音高（赫茲 Hz）。低頻在下，高頻在上，顯示聲音分佈的音域。



[熱力顏色] 能量振幅 (Amplitude)

顏色越偏向紅色/深色，代表該頻率在該時間點的能量越強；偏向藍色則代表能量微弱。這正是區分健康與病理理咳嗽的關鍵熱區。

🔍 如何解讀聲譜圖？

[水平 X 軸] 時間 (Time)

代表咳嗽聲發生的時間軸（秒）。可以清楚看出咳嗽的起始、爆發與餘音階段。

Step 6. 梅爾刻度轉換 (Mel Scale)：模擬人類聽覺的非線性映射

為什麼不直接使用物理頻率？

在物理世界中，頻率是線性的。然而，人類耳蝸的構造使得我們對低頻變化極度敏感，對高頻變化卻相當遲鈍。為了讓 AI 的判定標準貼近人耳，必須將物理頻率 (f) 轉換為聽覺感知的梅爾刻度 (m)。

核心映射公式

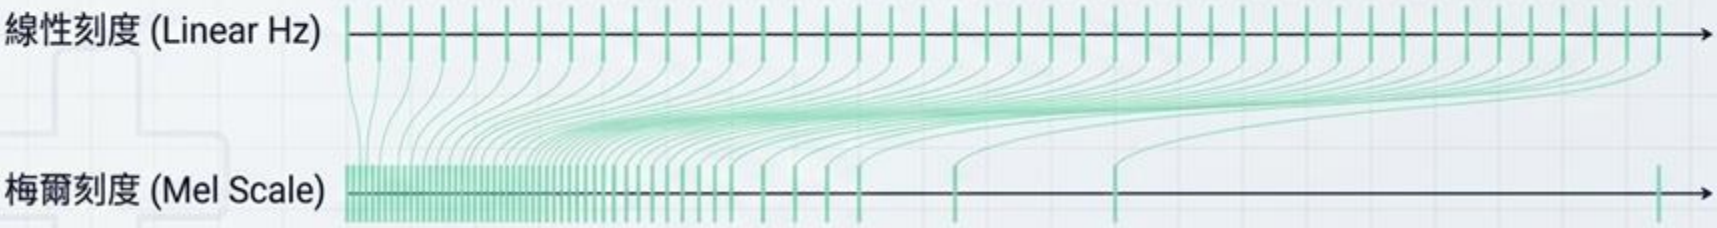
將線性赫茲轉換為仿生刻度：

$$m = 2595 \log_{10}\left(1 + \frac{f}{700}\right)$$

反向轉換（由梅爾轉回赫茲）：

$$f = 700\left(10^{\frac{m}{2595}} - 1\right)$$

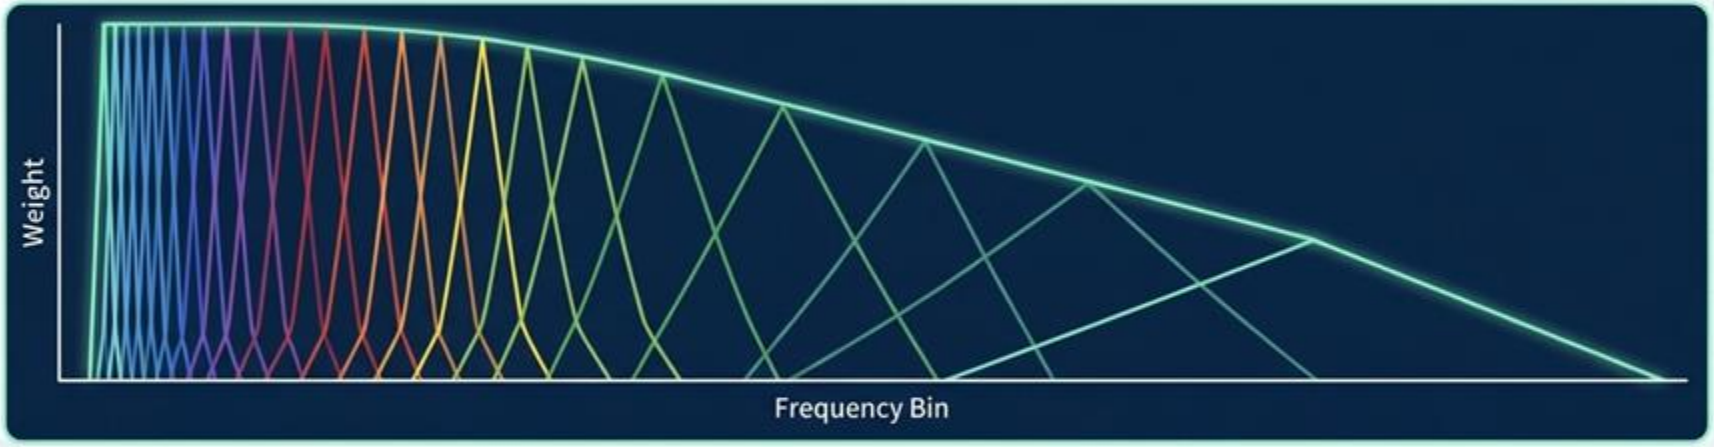
聽覺感知差異



非線性放大鏡：擴張低頻，壓縮高頻

Step 7. 三角濾波器 (Mel Filter Bank)：打造 AI 的數位耳蝸

基於梅爾刻度，我們在頻譜上佈置一組互相交疊的三角形濾波器，完美模擬人類內耳毛細胞接收聲音的機制，藉此萃取取出最具代表性的聲音特徵向量。



1. 低頻區：密集且狹窄

在頻譜圖左側，濾波器排列極為緊密，且頻寬較窄。

目的：針對人類聽覺最敏銳的區域進行「高解析度」的特徵掃描，絕不放過任何微小的低頻病理共鳴。

2. 高頻區：稀疏且寬闊

在頻譜圖右側，濾波器的間距被拉大，頻寬變得極寬。

目的：模擬人耳對高頻的模糊感知，將高頻細節進行「粗略打包」，大幅降低運算維度並過濾無效的高頻雜訊。

Step 8. 對數轉換 (Log Energy)：壓縮動態範圍與特徵成型

計算濾波器加權總能量

$$S[m] = \sum_{k=f_{\min}}^{f_{\max}} |X[k]|^2 \cdot H_m[k]$$

- $|X[k]|^2$：FFT 轉換後的頻率能量
- $H_m[k]$：第 m 個梅爾濾波器在頻率 k 的權重
- $S[m]$ ：該濾波器收集到的加權總能量

最終塑型：為什麼要取對數 $\log(S[m])$？

模擬聽覺感知

人類對音量大小的感受是對數的（分貝），取對數能讓數值更符合真實聽覺。

特徵穩定性

乘法雜訊在取對數後會轉化為加法雜訊，這讓後續處理能更輕易地將雜訊分離。

壓縮動態範圍

將極大與極小的能量值壓縮至合理的區間，避免後續 AI 建模演算法（如 SVM）受到極端值干擾。



NotebookLM

離散餘弦轉換 (DCT)

$$C[n] = \sum_{m=1}^{M} \log(S[m]) \cdot \cos\left[\frac{\pi}{M}(m - 0.5)n\right]$$

第 n 個 MFCC 特徵

將頻譜能量轉換至倒頻譜域 (Cepstral Domain)，提取最終音訊特徵。

對數能量值

第 m 個三角濾波器加權後的對數總能量。

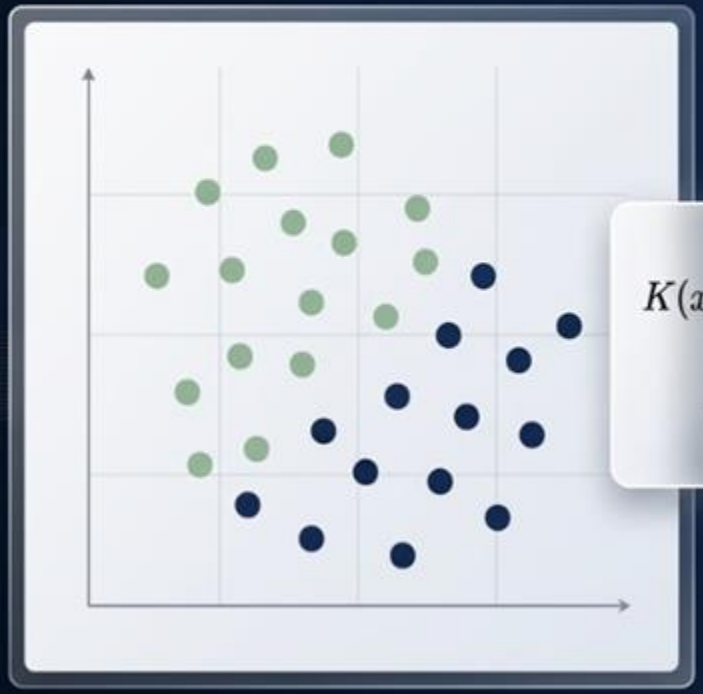
濾波器總數

梅爾濾波器組 (Mel Filter Bank) 的總數量參數。


【分類】
Classification

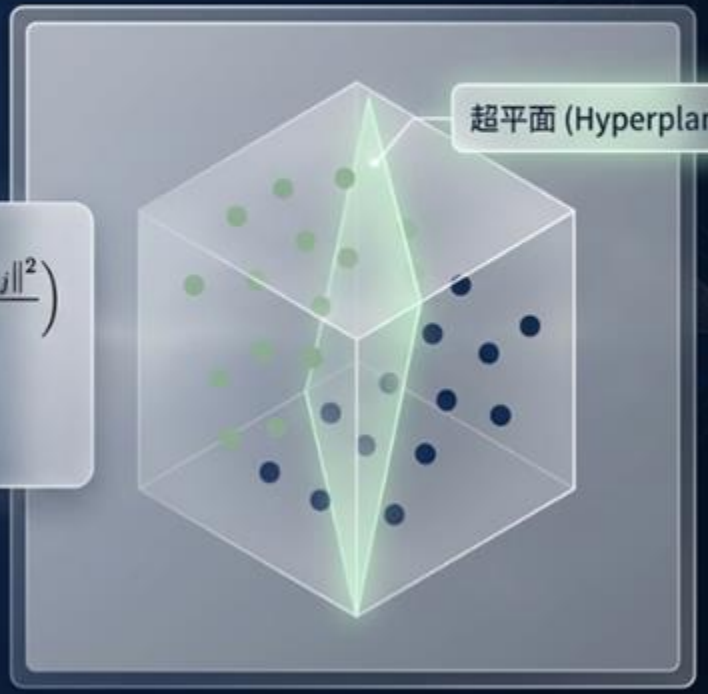
建模演算法：Support Vector Machine (SVM)

透過核函數 (Kernel Function) 映射，將原始數據點轉換至高維特徵空間以實現線性分離。



$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

$$K(x_i, x_j) = (x_i \cdot x_j)$$

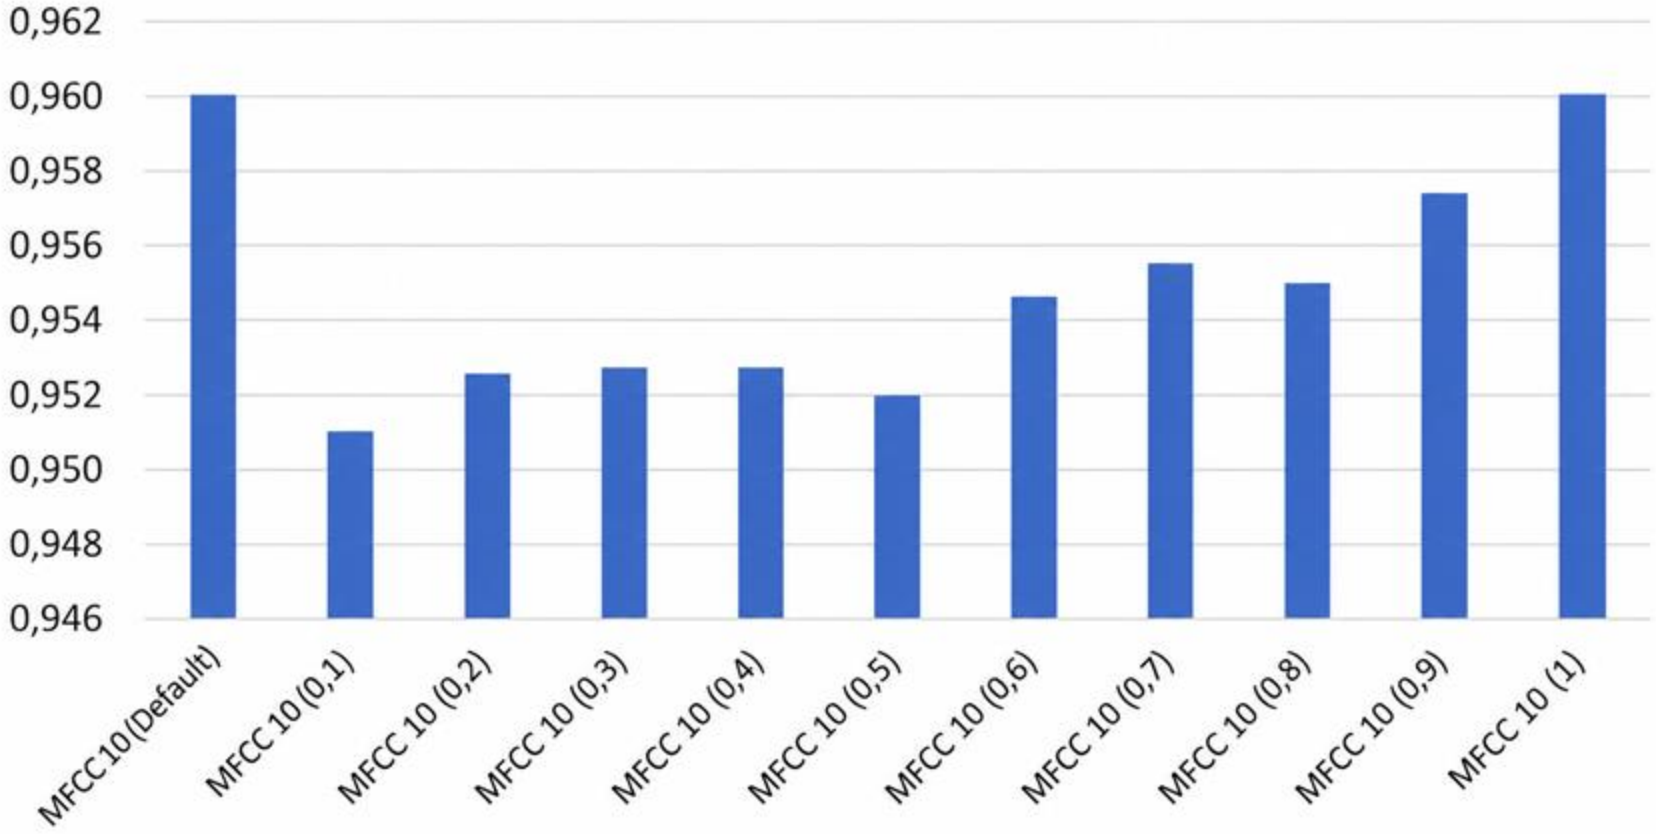


SVM超參數

Parameters	Description	Values
Kernel	Transforms the original feature space into an infinite feature space.	RBF & Linear
C	Controlling between margin and misclassification in SVM models.	0,1 - 1
Gamma	Control how much influence each center point has on the mapping.	0.062

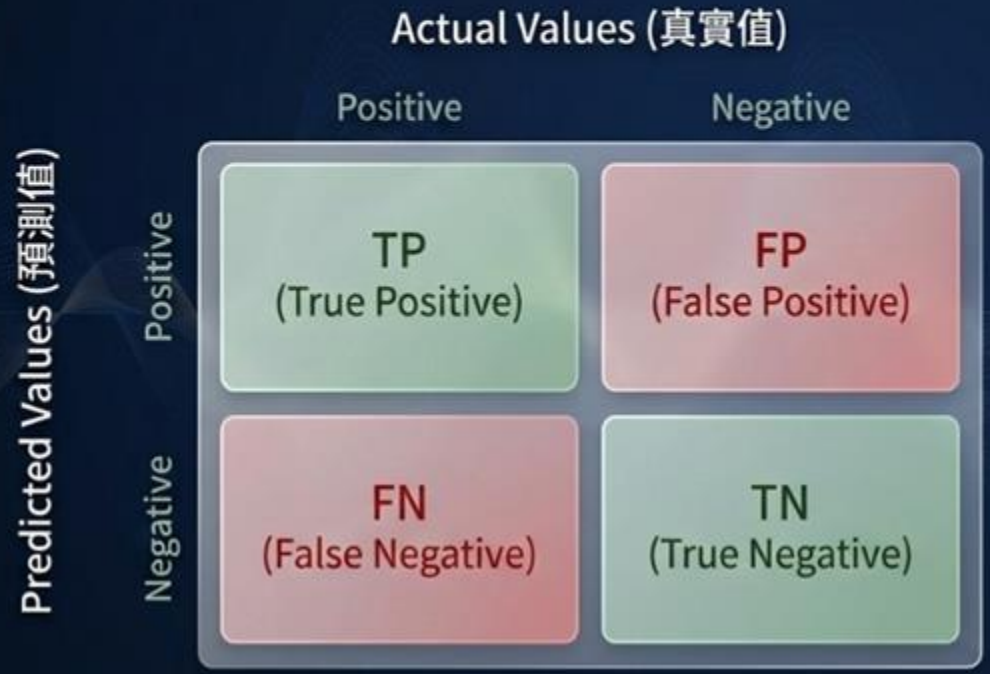
實驗發現C設為1是表現最好的

研究結果顯示以RBF來看，使用MFCC取十個參數 + C=1 有最佳陰陽性辨別(ACC)能力(oversampling)



模型評估標準：混淆矩陣 (Confusion Matrix)

以絕對真理標註 (Ground Truth) 為基準，嚴格檢視預測準確度。



$$ACC = \frac{TN + TP}{TP + FN + TN + FP}$$

各聲學特徵與建模方法成效完整比較矩陣

Feature Extraction	Classifier	Sampling Method	AUC	ACC
MFCC-stats	KNN	Undersampling	0.591	0.657
		SMOTE	0.773	0.586
		Oversampling	0.500	0.845
	SVM	Undersampling	1.000	0.008
		SMOTE	0.000	1.000
		Oversampling	0.000	1.000
	XGBoost	Undersampling	0.682	0.640
		SMOTE	0.500	0.695
		Oversampling	0.455	0.816
NMF-MFCC	KNN	Undersampling	0.500	0.603
		SMOTE	0.500	0.690
		Oversampling	0.273	0.845
	SVM	SMOTE	1.000	0.008
		Oversampling	0.000	1.000
	XGBoost	Undersampling	0.682	0.640
		SMOTE	0.545	0.753
		Oversampling	0.409	0.795
NMF-spectrogram	KNN	Undersampling	0.500	0.628
		SMOTE	0.773	0.594
		Oversampling	0.364	0.837
	SVM	Undersampling	0.909	0.556
		SMOTE	0.636	0.640
		Oversampling	0.682	0.724
	XGBoost	Undersampling	0.727	0.615
		SMOTE	0.591	0.649
		Oversampling	0.545	0.736
Proposed Method (Ours): NeMo MarbleNet		**Oversampling**	**0.992**	**0.960**
		Undersampling	0.978	0.935

```
...  Accuracy : 95.06 %

     Confusion Matrix:
     [[ 95   5   0   0   0]
      [ 25  55   0   0   0]
      [  0   0 289   0   0]
      [  0   0   1 180   5]
      [  0   0   3   4 208]]

     Evaluation Metrics:
     Accuracy  : 95.06 %
     Precision : 0.9299
     Recall    : 0.9145
     F1-score  : 0.9175

     Classification Report:
                   precision    recall  f1-score   s

                0       0.79      0.95      0.86
                1       0.92      0.69      0.79
                2       0.99      1.00      0.99
                3       0.98      0.97      0.97
                4       0.98      0.97      0.97

         accuracy                           0.95
        macro avg       0.93      0.91      0.92
     weighted avg       0.95      0.95      0.95
```

感謝聆聽